

Final Report: Bus ETA Correction for Map Application

Mục lục

- Final Report: Bus ETA Correction for Map Application
 - Mục lục
 - 1. Problem Context
 - 2. Goals
 - 3. Dataset
 - 4. Evaluation Metrics
 - 5. Methods, Metrics, and Comments
 - 5.1 API / Vietmap Baseline
 - 5.2 Additive Residual Correction
 - 5.3 Ratio / Multiplicative Correction
 - 5.4 Log-ratio Correction
 - 5.5 Affine Correction with Huber Regression
 - 5.6 ML and Deep Learning Methods
 - 6. Overall Comparison
 - 7. Final Solution
 - Primary Solution
 - Secondary Solution
 - Production Recommendation
 - 8. Limitations and Next Steps

1. Problem Context

Trong hệ thống map hiện tại, một tính năng quan trọng là **bus ETA**: ước lượng thời gian xe buýt di chuyển hoặc đến điểm đón/điểm đến. Hệ thống đã có sẵn ETA ban đầu từ map/routing API:

```
api_eta_secs = estimate_time  
actual_eta_secs = delta_time
```

estimate_time là ETA do routing engine trả về, còn **delta_time** là thời gian thực tế quan sát được. Routing API đã là một baseline mạnh, nhưng trong thực tế bus ETA vẫn có thể sai do:

- Traffic pattern thay đổi theo khung giờ.
- Xe buýt dừng đón/trả khách.
- Đèn đỏ, congestion, incident hoặc thời tiết.
- Bias của routing API trên một route hoặc một số time-bin cụ thể.

Vì API ETA đã có chất lượng tương đối tốt, hướng tiếp cận hợp lý không phải là thay thế hoàn toàn API bằng model mới, mà là **ETA correction / residual correction**:

```
corrected_eta = api_eta + correction
```

hoặc ở dạng tỷ lệ:

```
corrected_eta = api_eta * correction_ratio
```

Mục tiêu là tận dụng estimate tốt từ routing API, sau đó học phần sai lệch có tính hệ thống từ dữ liệu lịch sử.

2. Goals

Mục tiêu sản phẩm và mô hình:

1. Cải thiện độ chính xác của bus ETA hiển thị trên map.
2. Giảm các lỗi lớn, vì ETA sai nặng ảnh hưởng trực tiếp đến trải nghiệm người dùng khi chờ xe buýt.
3. Giữ phương pháp đủ đơn giản để triển khai production, dễ giải thích và dễ monitor.
4. Ưu tiên mô hình có bias-variance tradeoff tốt với dataset hiện tại còn nhỏ.
5. Xác định phương pháp chính và phương pháp fallback cho hệ thống bus ETA.

Với use case bus ETA trên map, **P95/tail-error quan trọng hơn chỉ tối ưu MAE**, vì một số case ETA sai rất lớn có thể gây trải nghiệm tệ hơn nhiều so với nhiều sai số nhỏ.

3. Dataset

Dữ liệu chính gồm:

```
estimate_time: ETA từ map/routing API  
delta_time: thời gian di chuyển thực tế  
hour / time_bin: thông tin thời điểm khởi hành
```

Dữ liệu được chia theo thời gian:

```
Train: 215 rows  
Validation: 46 rows  
Test: 47 rows  
Split: chronological 70% / 15% / 15%
```

Việc chia theo thời gian phù hợp hơn random split vì bài toán ETA có yếu tố temporal. Cách chia này tránh tình huống model học từ dữ liệu tương lai để dự đoán quá khứ.

Các time-bin được sử dụng trong một số phương pháp:

```
early_morning: 4-6
morning_peak: 7-9
off_peak_day: 10-14
evening_peak: 15-18
late_evening: 19-21
```

Nhận xét về dữ liệu:

- Dataset hiện tại còn nhỏ, đặc biệt test set chỉ có 47 samples.
- Một số time-bin có thể sparse, ví dụ late evening.
- Feature hiện tại còn hạn chế, chủ yếu xoay quanh ETA API và thông tin thời gian.
- Vì route tương đối cố định, các correction thống kê đơn giản có lợi thế lớn so với model phức tạp.

4. Evaluation Metrics

Các metrics được sử dụng:

```
MAE: lỗi tuyệt đối trung bình, phản ánh sai số trung bình.
RMSE: nhạy với lỗi lớn, phạt mạnh các case sai nặng.
MAPE: lỗi phần trăm, nhạy với các chuyển ngắn.
P50: median absolute error.
P95: lỗi ở nhóm 5% case tệ nhất, đại diện cho tail-error.
R2: mức giải thích variance so với baseline trung bình.
```

Trong bus ETA, cách đọc metric nên ưu tiên:

- **MAE** để đánh giá độ chính xác trung bình.
- **P95 và RMSE** để đánh giá khả năng giảm lỗi lớn.
- **MAPE** để kiểm tra ảnh hưởng trên các chuyển ngắn.

5. Methods, Metrics, and Comments

5.1 API / Vietmap Baseline

Công thức:

```
prediction = estimate_time
```

Kết quả test set:

```
MAE  = 37.956s
RMSE = 56.887s
MAPE = 18.34%
```

```
P50  = 23.079s
P95  = 123.750s
R2    = 0.034
```

Nhận xét:

- Đây là baseline thực tế, có sẵn từ routing engine.
- MAPE tốt nhất trong các phương pháp hiện tại.
- Không cần training, dễ triển khai.
- Điểm yếu chính là P95 cao, nghĩa là vẫn có các case ETA sai lớn.
- API có xu hướng underestimate trong một số ngữ cảnh, nên correction vẫn có giá trị.

5.2 Additive Residual Correction

Công thức chung:

```
residual = actual_eta_secs - api_eta_secs
corrected_eta = estimate_time + predicted_residual
```

Các biến thể:

```
additive_global:
corrected_eta = estimate_time + median(train.residual)

additive_time_bin:
corrected_eta = estimate_time + median(train.residual | time_bin)

additive_smoothed_time_bin:
corrected_eta = estimate_time + smoothed_residual_by_time_bin
```

Kết quả:

method	MAE	RMSE	MAPE	P95	MAE vs API
P95 vs API					
api_eta	37.956	56.887	18.34%	123.750	0.00%
0.00%					
additive_global	37.249	52.804	19.58%	107.954	+1.86%
+12.76%					
additive_time_bin	37.965	51.794	20.45%	98.936	-0.02%
+20.05%					
additive_smoothed_time_bin	38.073	52.159	20.40%	103.111	-0.31%
+16.68%					

Nhận xét:

- `additive_global` là baseline correction rất mạnh: đơn giản, ổn định, MAE tốt.
- `additive_time_bin` không cải thiện MAE nhưng giảm P95 mạnh, từ **123.750s** xuống **98.936s**.
- `additive_smoothed_time_bin` robust hơn về mặt phương pháp, vì giảm rủi ro overfit ở bin ít sample.
- MAPE của nhóm additive tệ hơn API baseline, vì cộng offset cố định có thể làm tăng lỗi tương đối trên chuyển ngắn.

Kết luận:

- Nếu cần fallback cực kỳ dễ giải thích, `additive_global` là lựa chọn tốt.
- Nếu ưu tiên giảm tail-error, additive time-bin đã cho thấy hướng đi đúng: correction nên phụ thuộc vào khung giờ.

5.3 Ratio / Multiplicative Correction

Công thức:

```
ratio = actual_eta_secs / estimate_time
corrected_eta = estimate_time * ratio
```

Các biến thể:

```
ratio_global:
corrected_eta = estimate_time * median(train.actual_eta_secs /
train.estimate_time)

ratio_time_bin:
corrected_eta = estimate_time * median(train.actual_eta_secs / train.estimate_time
| time_bin)

ratio_smoothed_time_bin:
corrected_eta = estimate_time * smoothed_ratio_by_time_bin
```

Global ratio học được:

```
global_ratio = 1.1009
```

Điều này nghĩa là ở mức median trên train set, actual bus travel time cao hơn API ETA khoảng **10.09%**.

Kết quả:

method	MAE	RMSE	MAPE	P50	P90	P95
R2						
ratio_global	37.237	52.529	19.60%	30.309	68.764	
108.039 0.176						

ratio_time_bin 0.217	38.018	51.202	20.69%	32.327	66.063	97.279
ratio_smoothed_time_bin 0.217	38.018	51.202	20.69%	32.327	66.063	97.279

So với API baseline:

method	MAE improvement	P95 improvement
ratio_global	+1.89%	+12.70%
ratio_time_bin	-0.16%	+21.39%
ratio_smoothed_time_bin	-0.16%	+21.39%

Nhận xét:

- **ratio_global** có MAE tốt nhất trong toàn bộ các phương pháp đã thử: **37.237s**.
- **ratio_time_bin** có RMSE và P95 tốt nhất: **RMSE = 51.202s**, **P95 = 97.279s**.
- Ratio correction phù hợp khi API sai theo tỷ lệ, không chỉ sai theo offset cộng thêm.
- **ratio_time_bin** đánh đổi MAE rất nhỏ để giảm lỗi lớn mạnh nhất.
- Với bus ETA, trade-off này hợp lý nếu sản phẩm ưu tiên tránh các case ETA sai nặng.

5.4 Log-ratio Correction

Công thức:

```
log_residual = log(actual_eta_secs / estimate_time)
corrected_eta = estimate_time * exp(log_residual)
```

Kết quả:

method	MAE	RMSE	MAPE	P50	P90	P95
R2						
log_ratio_global 108.039 0.176	37.237	52.529	19.60%	30.309	68.764	
log_ratio_time_bin 0.217	38.018	51.202	20.69%	32.327	66.063	97.279
log_ratio_smoothed_time_bin 0.217	38.018	51.202	20.69%	32.327	66.063	97.279

Nhận xét:

- Kết quả gần như trùng với ratio correction.
- Về lý thuyết, log-ratio robust hơn khi ratio lệch phải hoặc có outlier lớn.
- Trong setup hiện tại, vì dùng median và ratio luôn dương, **exp(median(log(ratio)))** gần như tương đương **median(ratio)**.

- Log-ratio có thể hữu ích hơn nếu sau này dùng regression/model học trong log-space.

Kết luận:

- `log_ratio_global` có thể xem là tương đương `ratio_global`.
- `log_ratio_time_bin` có thể xem là tương đương `ratio_time_bin`.
- Nếu ưu tiên giải thích đơn giản cho production, ratio thường dễ truyền đạt hơn log-ratio.

5.5 Affine Correction with Huber Regression

Công thức:

$$\text{corrected_eta} = a * \text{estimate_time} + b$$

Affine tổng quát hơn additive và ratio:

Nếu $a = 1$ và $b \neq 0$ -> gần với additive correction
 Nếu $a \neq 1$ và $b = 0$ -> gần với ratio correction
 Nếu $a \neq 1$ và $b \neq 0$ -> vừa scale vừa dịch offset

Do residual có outlier và distribution lệch phải, affine được fit bằng Huber Regression:

```
estimator = sklearn.linear_model.HuberRegressor
epsilon    = 1.35
alpha      = 0.0001
max_iter   = 1000
```

Global affine học được:

```
a = 0.1595
b = 150.7553
```

Kết quả:

method	MAE	RMSE	MAPE	P95	MAE vs API
P95 vs API					
affine_global	39.812	56.781	21.31%	111.769	-4.89%
+9.68%					
affine_time_bin	41.758	56.609	23.00%	100.859	-10.02%
+18.50%					
affine_smoothed_time_bin	40.403	56.443	21.97%	107.764	-6.45%
+12.92%					

Nhận xét:

- Affine vẫn cải thiện P95 so với API baseline.
- Tuy nhiên MAE tệ hơn API baseline khá rõ.
- Global affine có intercept lớn, khiến prediction bị kéo mạnh về một mức trung tâm.
- Với dataset nhỏ và test set chỉ 47 samples, affine có dấu hiệu nhạy với split hoặc mismatch giữa validation và test.

Kết luận:

- Chưa nên chọn affine làm primary method.
- Có thể giữ affine như diagnostic method để kiểm tra quan hệ tuyến tính giữa API ETA và actual ETA.

5.6 ML and Deep Learning Methods

Các phương pháp đã thử:

```
MLP residual ETA
Hour-bin MLP residual ETA
DeeprETA-like
XGBoost residual/direct ETA
```

Kết quả:

method	MAE	RMSE	MAPE	P95
MLP residual ETA	37.612	52.661	19.43%	101.684
Hour-bin MLP residual ETA	38.297	54.500	19.41%	107.584
DeeprETA-like	38.453	52.213	20.95%	99.546
xgb_residual_eta	42.639	n/a	n/a	106.104
hour_bin_xgb_residual_eta	43.383	n/a	n/a	113.415
xgb_direct_eta	44.914	n/a	n/a	99.304

Nhận xét:

- **MLP residual ETA** là ML residual model tốt nhất hiện tại, nhưng vẫn không thắng **ratio_global** về MAE và không thắng **ratio_time_bin** về P95.
- **DeeprETA-like** có P95 tương đối tốt, nhưng MAE và MAPE kém hơn các correction đơn giản.
- XGBoost kém rõ theo MAE; một số biến thể có P95 khá nhưng đánh đổi quá lớn ở sai số trung bình.
- Với dataset nhỏ và feature hạn chế, model phức tạp dễ học noise hơn là pattern thật.

Lý do model phức tạp chưa vượt baseline:

- Dữ liệu còn nhỏ.
- Feature chưa đủ phong phú: thiếu weather, traffic condition, holiday, bus stop dwell time, road segment, route polyline.
- Bài toán hiện tại tập trung vào một route cố định, nên statistical correction đã rất mạnh.
- Residual có nhiều noise không quan sát được.

- Một số time-bin ít sample, dễ gây overfit.

6. Overall Comparison

Bảng tổng hợp các phương pháp quan trọng:

method	MAE	RMSE	MAPE	P95	Main comment
api_eta	37.956	56.887	18.34%	123.750	Best MAPE,
strong no-training baseline					
additive_global	37.249	52.804	19.58%	107.954	Simple, stable,
strong fallback					
additive_time_bin	37.965	51.794	20.45%	98.936	Strong tail-
error reduction					
additive_smoothed_time_bin	38.073	52.159	20.40%	103.111	More robust for
sparse bins					
ratio_global	37.237	52.529	19.60%	108.039	Best MAE
ratio_time_bin	38.018	51.202	20.69%	97.279	Best RMSE and
P95					
log_ratio_global	37.237	52.529	19.60%	108.039	Equivalent to
ratio_global here					
log_ratio_time_bin	38.018	51.202	20.69%	97.279	Equivalent to
ratio_time_bin here					
affine_global	39.812	56.781	21.31%	111.769	Worse MAE,
improves P95					
affine_time_bin	41.758	56.609	23.00%	100.859	Stronger P95,
poor MAE					
MLP residual ETA	37.612	52.661	19.43%	101.684	Best ML model,
not best overall					
DeeprETA-like	38.453	52.213	20.95%	99.546	Good P95, too
complex for current gain					
xgb_direct_eta	44.914	n/a	n/a	99.304	Good P95, poor
MAE					

Best by objective:

Best MAE: API + Global Ratio / Global Log-ratio Correction
Best RMSE: API + Time-bin Ratio / Time-bin Log-ratio Correction
Best P95: API + Time-bin Ratio / Time-bin Log-ratio Correction
Best MAPE: API baseline
Best additive fallback: API + Global Median Residual

Best ML residual model:

MLP Residual ETA

Most production-friendly:

API + Global Ratio Correction or API + Global Median Residual

Best for bus ETA tail-error:

API + Time-bin Ratio Correction

7. Final Solution

Primary Solution

Chọn:

API + Time-bin Ratio Correction

Công thức:

```
ratio_by_time_bin = median(train.actual_eta_secs / train.estimate_time | time_bin)
corrected_eta = estimate_time * ratio_by_time_bin
```

Kết quả:

```
MAE  = 38.018s
RMSE = 51.202s
MAPE = 20.69%
P95  = 97.279s
R2   = 0.217
```

So với API baseline:

```
MAE improvement = -0.16%
P95 improvement = +21.39%
```

Lý do chọn:

- Có P95 tốt nhất trong toàn bộ các phương pháp: **97.279s**.
- Có RMSE tốt nhất: **51.202s**.
- Giảm lỗi lớn mạnh nhất, phù hợp với bus ETA trên map.
- Khai thác được bias khác nhau theo khung giờ.

- Correction dạng tỷ lệ hợp lý hơn khi sai số API scale theo độ dài ETA.
- Công thức đơn giản, không cần model phức tạp, dễ triển khai và monitor.

Trade-off:

- MAE kém API baseline rất nhẹ: **38.018s** so với **37.956s**.
- MAPE cao hơn API baseline.
- Time-bin sparse có thể gây over-correction nếu triển khai trên dữ liệu ít.

Với mục tiêu sản phẩm là bus ETA đáng tin hơn, đặc biệt giảm các case sai nặng, trade-off này chấp nhận được.

Secondary Solution

Chọn:

API + Global Ratio Correction

Công thức:

```
global_ratio = median(train.actual_eta_secs / train.estimate_time)
corrected_eta = estimate_time * global_ratio
```

Kết quả:

```
MAE   = 37.237s
RMSE  = 52.529s
MAPE  = 19.60%
P95   = 108.039s
```

Lý do giữ làm secondary/fallback:

- Có MAE tốt nhất trong toàn bộ các phương pháp.
- Cải thiện MAE **+1.89%** và P95 **+12.70%** so với API baseline.
- Đơn giản hơn time-bin ratio.
- Ổn định hơn khi dữ liệu trong từng time-bin còn ít.
- Phù hợp nếu production muốn ưu tiên sai số trung bình và giảm rủi ro sparse-bin.

Production Recommendation

Khuyến nghị triển khai theo hai tầng:

```
Nếu time_bin có đủ dữ liệu lịch sử:
    corrected_eta = estimate_time * ratio_by_time_bin
```

```
Nếu time_bin thiếu dữ liệu hoặc ratio bất thường:  
corrected_eta = estimate_time * global_ratio
```

Có thể thêm guardrail:

```
ratio_min <= applied_ratio <= ratio_max
```

và monitor định kỳ:

```
MAE, RMSE, MAPE, P95 theo ngày / tuần / time_bin
```

Kết luận cuối cùng:

```
Primary method:  
API + Time-bin Ratio Correction
```

```
Fallback method:  
API + Global Ratio Correction
```

```
Simple sanity-check baseline:  
API + Global Median Residual
```

8. Limitations and Next Steps

Limitations:

- Dataset hiện tại còn nhỏ, test set chỉ có 47 samples.
- Một số time-bin có thể thiếu dữ liệu.

Next steps:

1. Đánh giá bằng rolling hoặc expanding-window validation.
2. Tune smoothing cho time-bin ratio để giảm rủi ro sparse-bin.
3. Thêm guardrail cho ratio khi triển khai production.
4. Log prediction, actual ETA và error theo time-bin để monitor drift.
5. Khi dữ liệu lớn hơn, thử lại MLP/XGBoost/DeepETA-like với feature phong phú hơn.